Kernel PCA and de-noising in feature spaces

Based on the work by S. Mika et al.

Donignon Sékou Yeo, Koffi Roland Wotobe

Université Côte d'Azur

18 Février 2026

Introduction

- Kernel PCA pour la reconstruction des données et le débruitage
- Approximation des pré-images avec l'utilisation des noyaux gaussiens.

Kernel PCA

Considérons le jeu de données $\mathcal{X} = \{x_1, ..., x_l\}$ with $x_i \in \mathbb{R}^N$

- Kernel PCA associe $\mathcal{X}$ dans un espace des caractéristiques à dimension élevée $\mathbf{F}$

$$\Phi : \mathbb{R}^N \to \mathbf{F}$$

  $\Phi(x_i)$ est connue comme la Φ-image of x_i.
- Après l'algorithme du PCA linéaire est réalisé dans in $\mathbf{F}$ en utilisant un operateur de projection sur les n composantes principales dans $\mathbf{F}$ comme P_n.

Reconstruction et pré-images

Etant donné un point de test $t \in \mathbb{R}^N$:

- Nous reconstruisons son comme $P_n\Phi(t)$.
- Nous trouvons son pré-image $z \in \mathbb{R}^N$ tel que $\Phi(z) \approx P_n\Phi(t)$
- Nous effectuons cela en minimisant la fonction objectif suivante:

$$||\Phi(z) - P_n\Phi(t)||^2 \tag{1}$$

Le "Kernel trick"

- En utilisant le Kernel trick on peut éviter de faire des opérations dans des espaces de dimnension élevés
- En utlisant les noyaux gaussiens, il est possible de construire un schéma itératif permettant d'obtenir une approximation de la pré-image

$$k(x_i, x_j) = \exp(-||x_i - x_j||^2/c) \tag{2}$$

Toy Example: 11 Gaussians

- 11 gaussiens sphériques avec centres aléatoires dans $[-1, 1]^{10}$
- Echantillonnage de 100 points de chaque pour les données d'entraînement
- Echantillonnage de 33 points de chaque pour les données de test
- Débruitage des données de test à l'aide du noyau et de l'ACP linéaire entraînés sur les données d'entraînement.

Results

[Leur résultats]

σ	n=1	2	3	4	5	6	7	8	9
0.05	2058.42	1238.36	846.14	565.41	309.64	170.36	125.97	104.40	92.23
0.1	10.22	31.32	21.51	29.24	27.66	23.53	29.64	40.07	63.41
0.2	0.99	1.12	1.18	1.50	2.11	2.73	3.72	5.09	6.32
0.4	1.07	1.26	1.44	1.64	1.91	2.08	2.22	2.34	2.47
0.8	1.23	1.39	1.54	1.70	1.80	1.96	2.10	2.25	2.39

;

σ	$n = 1$	2	3	4	5	6	7
0.05	468.39	1467.76	1445.60	1092.73	795.31	470.32	294.24
0.1	113.43	321.01	339.63	285.5	200.84	122.45	68.46
0.2	38.73	97.34	101.1	27.59	30.9	5.28	2.57
0.4	9.73	3.94	2.45	5.95	3.11	8.33	11.49
0.8	0.61	1.15	1.35	1.50	1.69	1.72	1.64

Table: Nos résultats

Toy Example: Débruitage

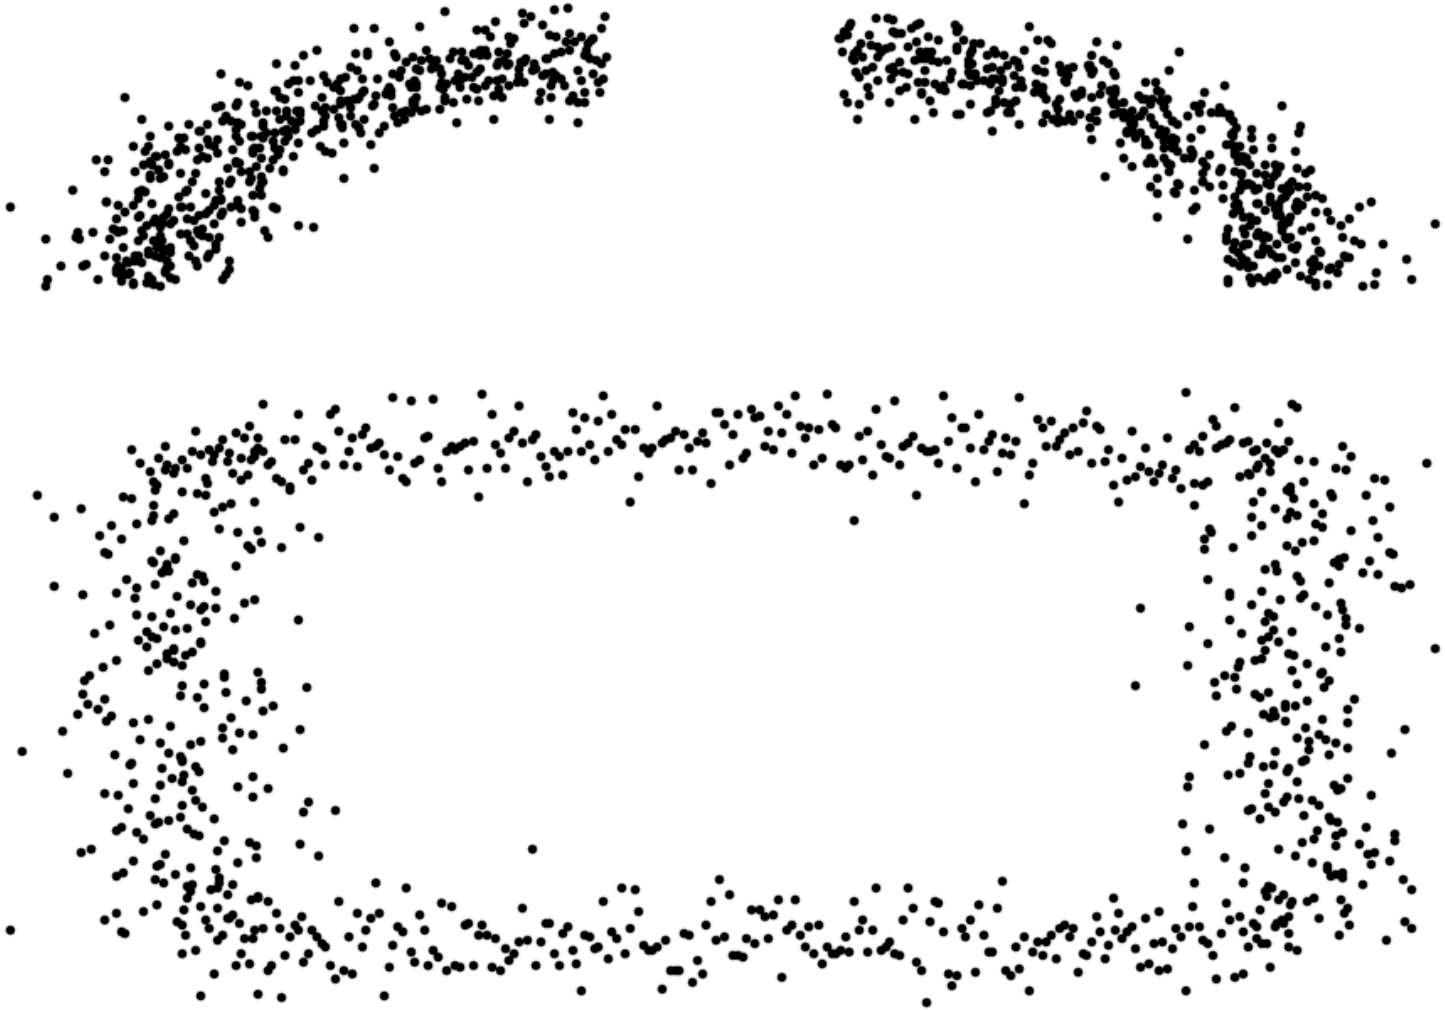

Toy Example: Débruitage

L'intention est de comparer les résultats du débruitage en utilisant l'ACP à noyau et d'autres algorithmes[cite: 93].

- Des données synthétiques sont générées à partir de différentes formes dans le plan auxquelles on ajoute du bruit
- L'utilisation de données bidimensionnelles permet une analyse subjective simple des résultats par inspection visuelle

Résultats

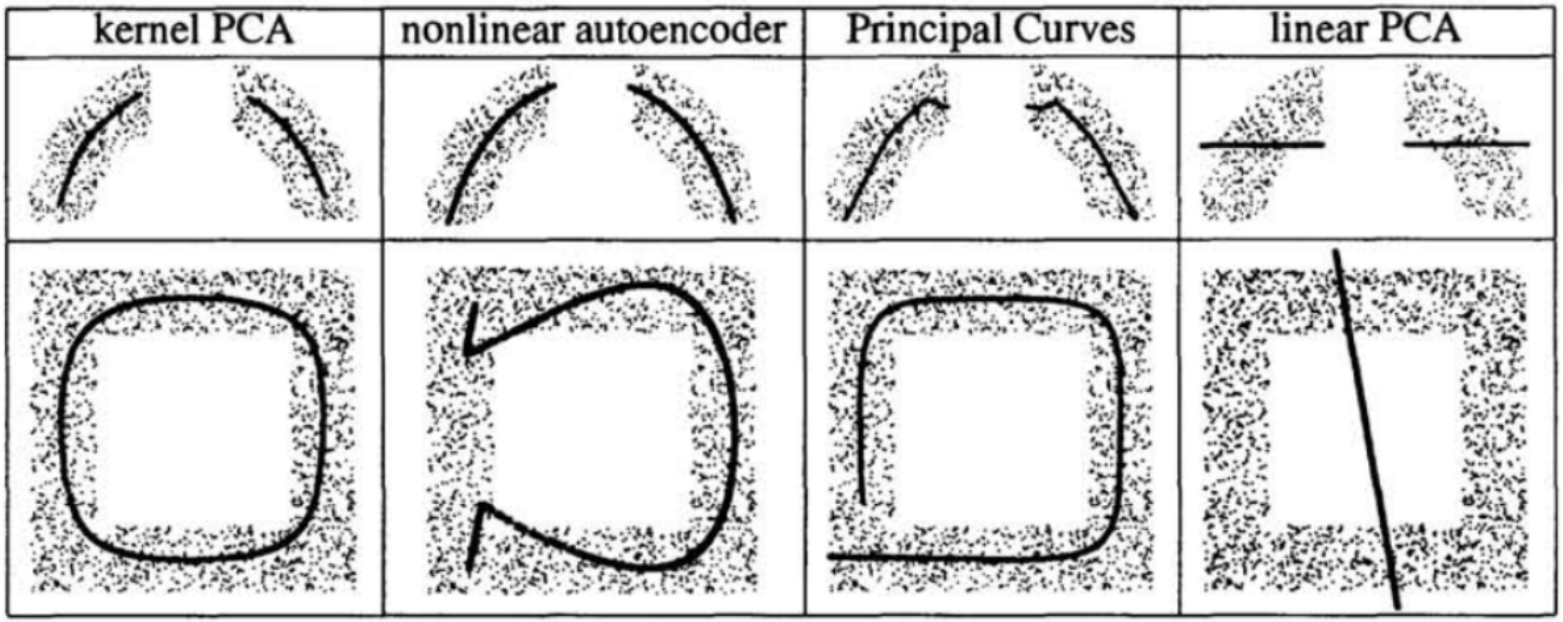
kernel PCA
nonlinear autoencoder
Principal Curves
linear PCA

;

Résultats

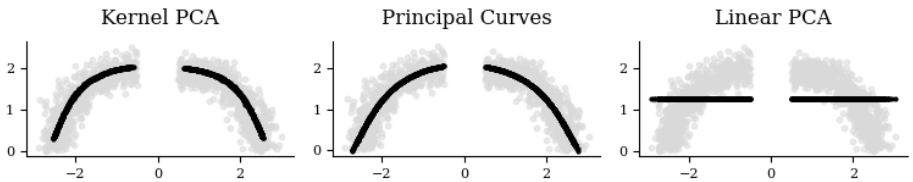
Kernel PCA
Principal Curves
Linear PCA

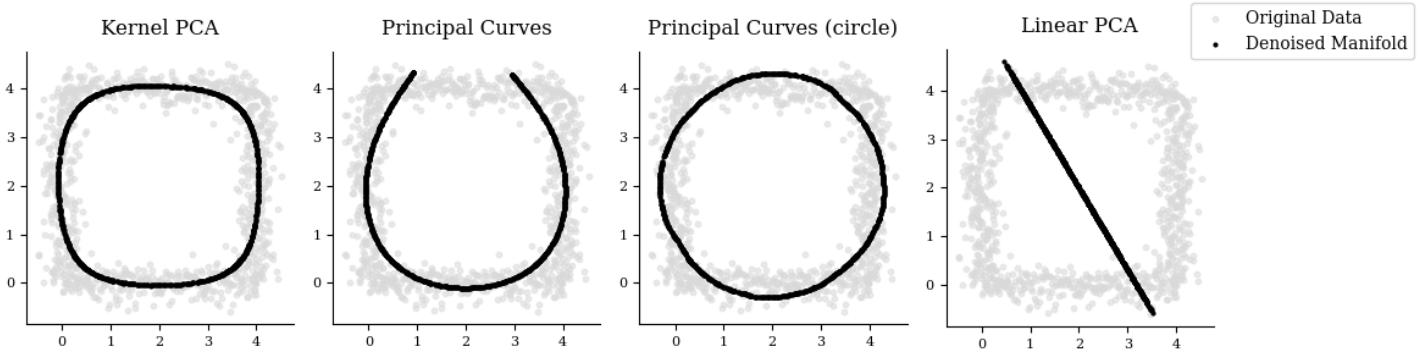
Kernel PCA
Principal Curves
Principal Curves (circle)
Linear PCA
Original Data
Denoised Manifold

;

Jeu de données USPS Débruitage

- 16×16 labeled images of handwritten digits.
- Total of 9298 observations (7291 training / 2007 testing)
- Noise models: Gaussian ($\sigma = 0.5$) and Speckle ($p = 0.4$)

Reconstruction: Linear vs Kernel PCA

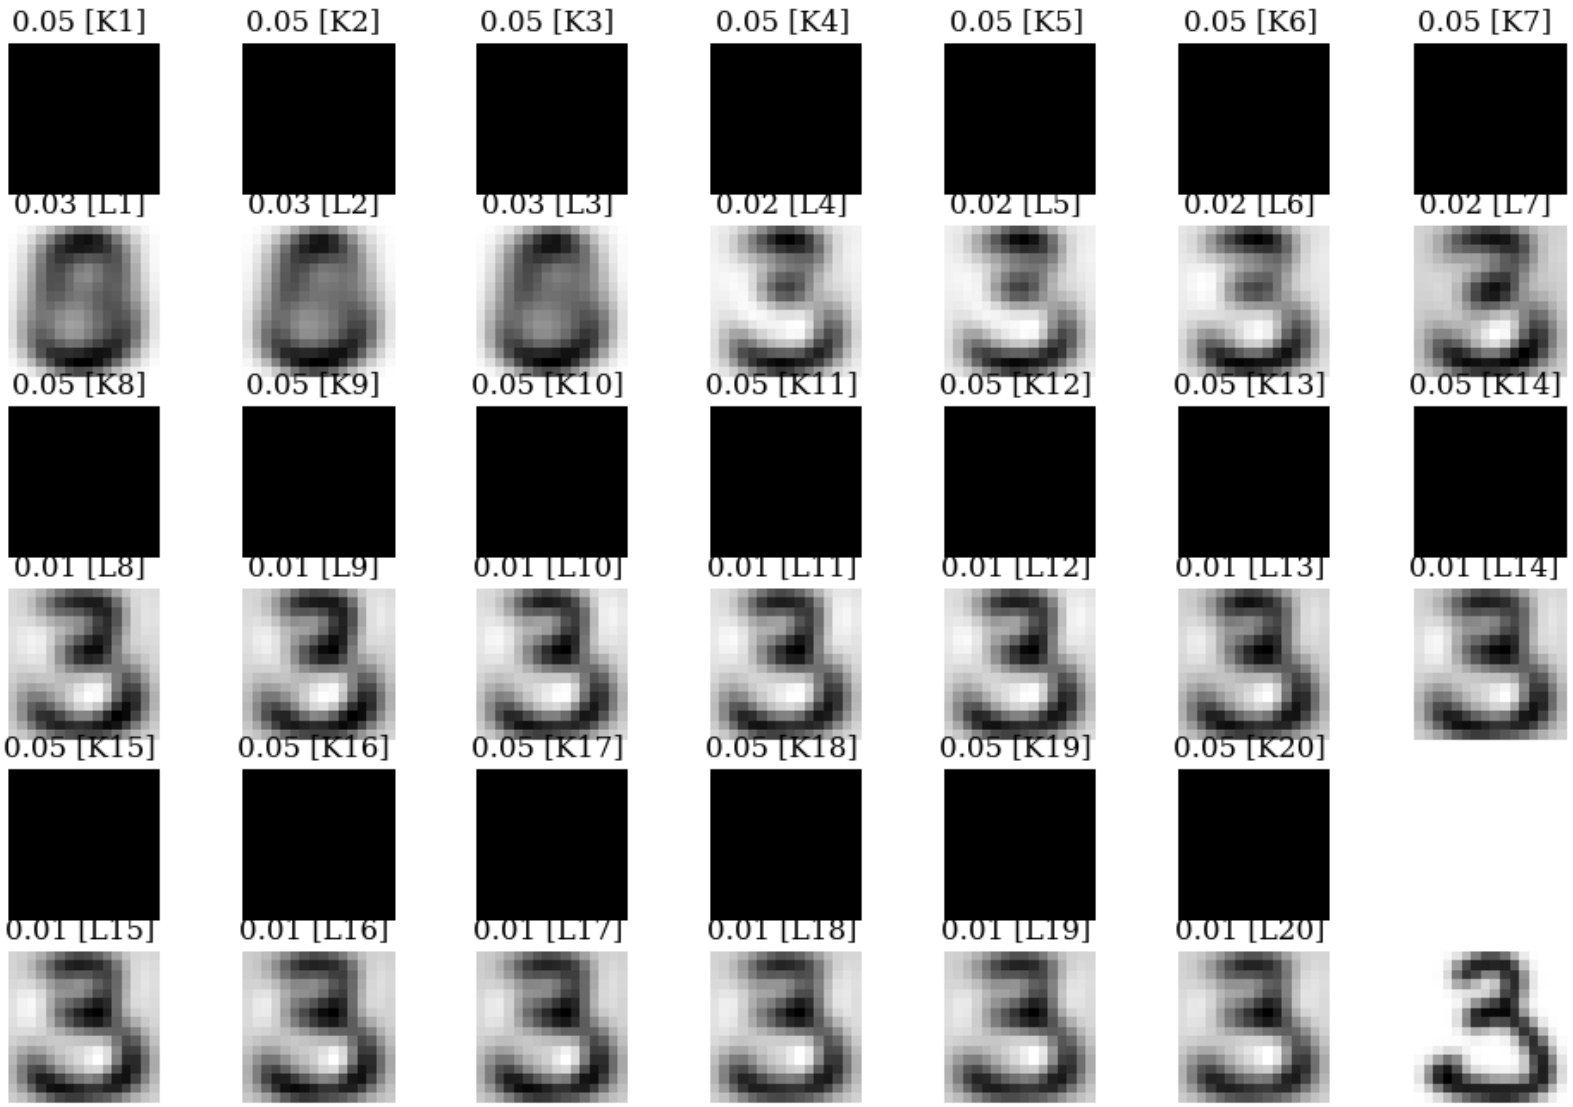

;

Conclusion

- Nous avons pu reproduire les résultats de Mika et al. results à environ 60%
- Kernel PCA est plus avantageux lorsqu'il s'agit d'extraction de caractéristiques non linéaires[cite: 320].
- **Trade-offs:**
  - Complexité en temps élevé: $k(t, x_i) \forall i$.
  - Complexité spatiale: Besoin de stocker toutes les données